

NBA Chat Agent

方案说明 · 面试交付版

目标：交付一个面向中文球迷的、可在线访问的 NBA 官方风格问答助手。本方案聚焦事实可信、安全合规和可复现的工程边界。

1. 产品思路

产品采用“事实链 + 受限分析”的双通道。比分、球员数据、赛程、排名、系列赛累计和逐回合事件，先从公开数据获取并归一化，再由确定性代码核验和推导；战术与复盘只在事实完成后交给受限模型组织语言。因此模型不能修改比分、做算术或绕过安全策略。

用户看到的是结论优先、结构化、简体中文的回答，默认北京时间（UTC+8），并明确数据截至时间和核验状态。左侧赛事焦点支持“今日赛事 / 历史回顾”，空日期和未来日期不会复用旧卡片。

2. 系统架构

浏览器 Web Demo → FastAPI Chat API → 检索前 Safety Guard → 会话/时区/意图解析 → Provider Gateway → Normalizer → Verifier/Derivation → 模板或 Hermes-lite/SiliconFlow → Output Guard。

模块	职责	边界
Safety Guard	识别红线并在检索前拒答	不搜索敏感问题
Provider Gateway	公开数据、超时、重试、缓存和 fallback	唯一外网访问边界
Verifier / Derivation	核验事实，确定性汇总系列赛与 PBP	模型不参与算术和选球
Hermes-lite	仅组织已核验事实的战术/复盘措辞	无 Provider、浏览器、Shell、Memory、MCP
Output Guard	拦截无证据数字、敏感内容和内部字段	模型输出不直接信任

3. 数据获取与事实准确性

实时剖面使用公开 ESPN Web API 适配器（HTTPS allow-list、超时、响应大小上限和有界重试）；hybrid 模式在上游异常时回退到版本化 fixture，避免演示不可用。业务层只依赖 Provider port，不绑定供应商字段。用户回答不暴露供应商名称、端点或内部字段。

所有缺失值保持 null 并显示“暂无数据/部分核验”。系列赛大比分、连胜和最后 5 秒事件由真实记录确定性计算；时间先统一为 UTC，再按请求时区展示。赛季采用跨自然年标签，例如 2025-26。

4. 交互与 UI

前端是零构建 HTML/CSS/ES2022，实现赛事转播风格的三栏布局：赛事焦点、对话区、比赛 HUD/PBP。支持 POST-SSE 流式输出、加载阶段、停止生成、错误重试、响应式布局、日期可用性三态和文字回放。没有获得授权的直播视频源，因此首版只展示文字 PBP，不嵌入第三方视频。

对外演示增加共享密码：密码只从 Docker secret 读取，成功登录后发放短期 HttpOnly、SameSite Cookie；健康/就绪探针保持公开，聊天、赛事焦点和日期接口未认证时返回 401。

5. 模型与 Hermes 取舍

模型并不替代事实系统。默认 fixture/mock 模式完全离线；显式启用 live + hybrid + embedded_spike 后，只有战术（F）和复盘（G）问题调用 SiliconFlow OpenAI-compatible 接口，默认模型为 deepseek-ai/DeepSeek-V4-Flash。模型输入只含结构化 FactBundle，输出必须通过 Output Guard。

当前是 API 进程内的受限 Hermes-lite Spike，并非生产级独立 sidecar；这是为了快速完成可验证首版。正式生产可将同一 AgentRuntimePort 迁移到无工具、无网络、无文件系统的独立 sidecar。

6. 验证、评测与交付

黄金题集包含 18 条案例，覆盖 A–I 参考题型；评测 Runner 支持重复运行、七维评分、性能记录和安全一票否决。本地 pytest 覆盖模型、时间、Provider、HTTP/SSE、认证、运行时、失败路径和多轮上下文。

交付项	状态	入口
在线产品	已部署，单端口访问	http://115.190.174.39:8000/（需访问密码）
需求/HLD/LLD	已提交	specs/001-nba-chat-agent/
方案说明 PDF	本文件	docs/solution.pdf
运行配置	fixture / hybrid / live 可切换	README.md、docs/byok.md