

NBA Chat Agent

方案说明 · 面试交付版

目标：交付一个面向中文球迷的、可在线访问的 NBA 官方风格问答助手。本方案聚焦事实可信、安全合规和可复现的工程边界。

1. 产品思路

产品采用“确定性事实链 + 受控 Agent”的双通道。比分、球员数据、赛程、排名、系列赛累计和逐回合事件，先从公开数据获取并归一化，再由确定性代码核验和推导；全智能模式由 Hermes 理解问题并选择三个 NBA 工具。因此模型可以规划查询，但客观事实文本采用服务器观察，不能交换胜者与比分、把罚球/终场标记改成投篮、做算术或绕过安全策略。

用户看到的是结论优先、结构化、简体中文的回答，默认北京时间（UTC+8），并明确数据截至时间和核验状态。左侧赛事焦点支持“今日赛事 / 精彩回顾”，空日期和未来日期不会复用旧卡片。

2. 系统架构

浏览器 Web Demo → FastAPI Chat API → 检索前 Safety Guard → 会话/时区上下文 → hybrid 确定性通道或 Official Hermes Agent → NBA 工具 → Provider/Verifier/Derivation → Output Guard。

模块	职责	边界
Safety Guard	识别红线并在检索前拒答	不搜索敏感问题
Provider Gateway	公开数据、超时、重试、缓存和 fallback	唯一外网访问边界
Verifier / Derivation	核验事实，确定性汇总系列赛与 PBP	模型不参与算术和选球
Official Hermes Agent	理解问题并调用 nba_query / nba_schedule / nba_news	无通用网络、浏览器、Shell、Memory、MCP
Output Guard	客观语义 grounding；拦截无证据数字/专名和内部字段	模型输出不直接信任

3. 数据获取与事实准确性

实时剖面使用公开 ESPN Web API 适配器（HTTPS allow-list、超时、响应大小上限和有界重试）；hybrid 模式在上游异常时回退到版本化 fixture，避免演示不可用。业务层只依赖 Provider port，不绑定供应商字段。用户回答不暴露供应商名称、端点或内部字段。

所有缺失值保持 null 并显示“暂无数据/部分核验”。系列赛大比分、连胜和最后 5 秒事件由真实记录确定性计算；时间先统一为 UTC，再按请求时区展示。赛季采用跨自然年标签，例如 2025-26。

精彩回顾使用 SQLite 保存已经过公开模型校验的最近列表、历史区间和比赛详情。历史终场数据可先返回缓存再后台刷新；今日和进行中比赛只接受短时 fresh 数据。详情完整度只能前进，低字段或冲突比分不会覆盖已有版本。具名卷保证容器替换后仍可复用，缓存异常则失败开放到原数据链路。SQLite v4 为混合最近列表的每场比赛分别保留公开/演示来源，不把 aggregate mixed 套到所有卡片。

4. 交互与 UI

前端是零构建 HTML/CSS/ES2022，实现赛事转播风格的三栏布局：赛事焦点、对话区、比赛 HUD/PBP。支持 POST-SSE 流式输出、加载阶段、停止生成、错误重试、响应式布局、日期可用性三态和文字回放。历史请求在 250ms 内完成时不闪加载，慢请求保留原卡片并只提示一次。没有获得授权的直播视频源，因此首版只展示文字 PBP，不嵌入第三方视频。

对外演示增加共享密码：密码只从 Docker secret 读取，成功登录后发放短期 HttpOnly、SameSite Cookie；健康/就绪探针保持公开，聊天、赛事焦点和日期接口未认证时返回 401。

5. 模型与 Hermes 取舍

模型并不替代事实系统。默认 fixture/mock 模式完全离线；live + hybrid + embedded_agent 使用锁定的 hermes-agent==0.19.0 和官方 AI Agent，默认模型为 deepseek-ai/DeepSeek-V4-Flash。全智能请求在规则 Parser 之前进入有界 tool loop，输出必须通过本地 Output Guard。

Agent 只启用三个任务级 NBA 工具，Shell、文件系统、浏览器、通用搜索、MCP、Memory、Skills 和子代理均关闭。当前 embedded_agent 是 API 进程内的受控面试演示形态；正式生产可将 AgentOrchestratorPort 迁移到隔离 sidecar。

用户明确要求联网复核演示比赛时，系统跳过旧缓存并禁用快照 fallback，先按北京时间日期和主客对阵匹配唯一公开赛事 ID，再读取公开详情；无唯一匹配只说明不能升级核验，不会把演示数据伪装成实时结果。

同一网页聊天在用户点击“新对话”前保持一个稳定逻辑会话，并显式传入最近 4 个完整回合；底层原生 Memory 和会话数据库仍关闭。历史只用于理解“那场/最后那个球”等指代，每个事实追问都必须在当前轮重新调用 NBA 工具核验。新对话会同时隔离历史和选中比赛。

6. 验证、评测与交付

黄金题集包含 21 条案例，覆盖 A – I 参考题型和全智能验收题；评测 Runner 支持重复运行、七维评分、性能记录和安全一票否决。本地 441 项 pytest、17 项浏览器 E2E 及关系级对抗用例覆盖模型、时间、Provider、HTTP/SSE、认证、运行时、失败路径和多轮上下文。

交付项	状态	入口
在线产品	已部署，单端口访问	http://115.190.174.39:8000/（需访问密码）
需求/HLD/LLD	已提交	随交付物提供完整设计说明
方案说明 PDF	本文件	独立可阅读，不依赖代码托管信息
运行配置	fixture / hybrid / live 可切换	部署时通过环境配置与 Secret 注入