

NBA Chat Agent

方案说明 · 面试交付版

目标：交付一个面向中文球迷的、可在线访问的 NBA 官方风格问答助手。本方案聚焦事实可信、安全合规和可复现的工程边界。

1. 产品思路

产品采用“确定性事实链 + 受控 Agent”的双通道。比分、球员数据、赛程、排名、系列赛累计和逐回合事件，先从公开数据获取并归一化，再由确定性代码核验和推导；全智能模式把原始问题和同会话的可信上下文直接交给受控 Agent，由它选择 NBA 工具并完成最终综合。因此模型可以规划查询，但客观事实文本采用服务器观察，不能交换胜者与比分、把罚球/终场标记改成投篮、做算术或绕过安全策略。

用户看到的是结论优先、结构化、简体中文的回答，默认北京时间（UTC+8），并明确数据截至时间和核验状态。默认是漫游模式；用户显式进入赛事下钻后，左侧才加载最近比赛或自定义日期范围，空日期和未来日期不会复用旧卡片。

2. 系统架构

浏览器 Web Demo → FastAPI Chat API → 检索前 Safety Guard → 会话/时区上下文 → 确定性通道或受控 Agent → NBA 工具 → Provider/SQLite/BM25/Verifier/Derivation → Output Guard。

模块	职责	边界
Safety Guard	识别红线并在检索前拒答	不搜索敏感问题
Provider Gateway	公开数据、超时、重试、缓存和公开搜索源 failover	唯一外网访问边界；不挂载演示快照
SQLite 赛事索引	结构化比赛/球员/PBP 精确过滤，叙事文档 FTS5/BM25 召回	演示快照不写入公开索引；搜索摘要只保留部分证据
Verifier / Derivation	核验事实，确定性汇总系列赛与 PBP	模型不参与算术和选球
受控 Agent	理解问题并调用 nba_query / nba_schedule / nba_news / nba_search	无通用网络、浏览器、Shell、Memory、MCP；纯搜索不经过结构化新闻
Output Guard	客观语义 grounding；拦截无证据数字/专名和内部字段	模型输出不直接信任

3. 数据获取与事实准确性

实时剖面使用公开 ESPN Web API 适配器（HTTPS allow-list、超时、响应大小上限和有界重试）。live 与 hybrid 都只装配公开数据栈，不会构造或挂载 fixture fallback；公开源异常时返回真实的无数据、部分核验或类型化技术错误。fixture

仅用于显式离线演示和自动测试。业务层只依赖 Provider port，不绑定供应商字段。用户回答不暴露供应商名称、端点或内部字段。

所有缺失值保持 null 并显示“暂无数据/部分核验”。系列赛大比分、连胜和最后 5 秒事件由真实记录确定性计算；时间先统一为 UTC，再按请求时区展示。赛季采用跨自然年标签，例如 2025-26。

赛事下钻和聊天索引使用 SQLite 保存已经过公开模型校验的比赛、球员、PBP 和叙事文档。结构化字段采用关系过滤，文本证据采用实体/赛季约束后的 FTS5/BM25；纯网页搜索先读本地 BM25，缺失时才调用受控搜索适配器，避免额外消耗结构化新闻请求。搜索摘要始终是部分证据，不会升级为比分或统计事实。历史终场数据可先返回缓存再后台刷新；最近赛事先查完整本地索引窗口，远端扫描预算耗尽产生的 partial 空结果不会写入 recent 缓存；今日和进行中比赛只接受短时 fresh 数据。详情完整度只能前进，低字段或冲突比分不会覆盖已有版本。具名卷保证容器替换后仍可复用，缓存异常则失败开放到原公开数据链路。公开 profile 只投影公开赛事卡片，显式 fixture profile 只投影带演示标签的固定快照，两者不会在同一公开 fallback 链中混用。

搜索或模型额度耗尽时，公共响应使用供应商无关的能力提醒：若 SQLite 或已核验事实仍能回答，就保留答案并说明最新资料或开放性分析受限；若完全没有可用事实，则返回不可重试的技术失败，不伪装为“暂无数据”。本轮额度状态在共享缓存读写前剥离，不会污染后续请求。

4. 交互与 UI

前端是零构建 HTML/CSS/ES2022，实现赛事转播风格的三栏布局：赛事焦点、对话区、比赛 HUD/PBP。支持 POST-SSE 流式输出、加载阶段、停止生成、错误重试、响应式布局、日期可用性三态和文字回放。历史请求在 250ms 内完成时不闪加载，慢请求保留原卡片并只提示一次。永久额度耗尽会显示醒目的能力提醒且不提供无效重试按钮；临时限流或超时仍可重试。没有获得授权的直播视频源，因此首版只展示文字 PBP，不嵌入第三方视频。

对外演示增加共享密码：密码只从 Docker secret 读取，成功登录后发放短期 HttpOnly、SameSite Cookie；健康/就绪探针保持公开，聊天、赛事焦点和日期接口未认证时返回 401。

5. 模型与智能 Agent 取舍

模型并不替代事实系统。显式 fixture profile 完全离线；公开 live/hybrid profile 可使用锁定的受控智能 Agent。全智能请求保留用户原始问题，并在确定性模板之前直接进入有界 tool loop；Agent 获取结构化范围和同会话上下文，自主选择工具并完成回答，输出必须通过本地 Output Guard。

明确日期、对阵或 G# 的比赛过程问题先绑定结构化比赛查询，不用日期赛程观察代替复盘；结构化记录缺字段时，再以有界公开报道补充并明确部分核验。

Agent 只启用四个任务级 NBA 工具；Shell、文件系统、浏览器、任意 URL、通用网络、MCP、Memory、Skills 和子代理均关闭。运行时实现和内部品牌属于服务端部署细节，系统提示词、公开 UI、回答与流式事件只使用产品身份，不暴露这些内部信息。

用户明确要求联网复核演示比赛时，系统跳过旧缓存，先按北京时间日期和主客对阵匹配唯一公开赛事 ID，再读取公开详情；无唯一匹配只说明不能升级核验，不会把演示数据伪装成实时结果。公开数据栈从一开始就不包含快照 fallback。

同一网页聊天在用户点击“新对话”前保持一个稳定逻辑会话，并显式传入最近 4 个完整回合；底层原生 Memory 和会话数据库仍关闭。历史只用于理解“那场/最后那个球”等指代，每个事实追问都必须在当前轮重新调用 NBA 工具核验。Agent 推荐的场次只有解析到当前系列赛已核验候选时才会绑定；后续“刚推荐的那场”等追问会重新查询该 canonical game。新对话会同时隔离历史、选中比赛和推荐场次。

确定性恢复不是全智能主链，只在 Agent 超时、缺少可用观察、事实关系与可信记录冲突，或输出/安全守卫拒绝结果时触发。此时应用只从已完成的可信结构化记录和网页证据重组完整回答；真正查无记录才返回无数据，能力故障且没有任何可用事实时返回对应技术失败，不套用固定快照。

6. 验证、评测与交付

黄金题集包含 63 轮案例，覆盖 A – I 参考题型和全智能验收题；评测 Runner 支持重复运行、七维评分、性能记录和安全一票否决。本地 847 项 pytest、29 项浏览器 E2E 及关系级对抗用例覆盖模型、时间、Provider、HTTP/SSE、认证、运行时、失败路径和多轮上下文。

交付项	状态	入口
在线产品	已部署，单端口访问	http://115.190.174.39:8000/（需访问密码）
需求/HLD/LLD	已提交	随交付物提供完整设计说明
方案说明 PDF	本文件	独立可阅读，不包含仓库、代码托管或凭据资料
运行配置	公开 live/hybrid；显式 fixture 演示/测试	公开模式永不回退固定快照；Secret 仅服务端注入